

Roteiro de Especialização: Ciência de Dados com Python (3 Anos)

Ano 1: Fundamentos Analíticos e Exploração

Período	Domínio Técnico	Objetivos Acadêmicos e Práticos
Q1	Python para Dados	Domínio de NumPy (álgebra linear e vetores) e Pandas (DataFrames). Manipulação, limpeza e tratamento de dados ausentes.
Q2	Estatística Descritiva	Medidas de tendência central, dispersão e correlação. Visualização de dados com Matplotlib e Seaborn para análise exploratória (EDA).
Q3	SQL e Extração	Queries complexas, Joins e agregações. Consumo de dados via APIs (JSON) e bibliotecas de conexão como SQLAlchemy e Psycopg2.
Q4	Probabilidade	Distribuições (Normal, Poisson, Binomial), Teorema de Bayes e Testes de Hipótese (P-valor, Erros Tipo I e II).

Ano 2: Machine Learning e Modelagem Estatística

Período	Domínio Técnico	Objetivos Acadêmicos e Práticos
Q5	Aprendizado Supervisionado	Regressão Linear/Logística, Árvores de Decisão e KNN utilizando a biblioteca Scikit-learn. Métricas de erro (MSE, R^2 , F1-Score).
Q6	Ensemble e Validação	Modelos robustos: Random Forest, Gradient Boosting (XGBoost, LightGBM). Técnicas de Cross-Validation e Fine-tuning de hiperparâmetros.
Q7	Não Supervisionado	Agrupamento (K-Means, DBSCAN), Redução de Dimensionalidade (PCA, t-SNE) e Sistemas de Recomendação.
Q8	Feature Engineering	Técnicas avançadas de transformação de variáveis: One-Hot Encoding, Scaling, Box-Cox e seleção de atributos por importância.

Ano 3: IA Avançada e Engenharia de Produção (MLOps)

Período	Domínio Técnico	Objetivos Acadêmicos e Práticos
Q9	Deep Learning I	Introdução a Redes Neurais Artificiais, Funções de Ativação e Backpropagation utilizando TensorFlow ou PyTorch.
Q10	NLP e Visão	Processamento de Linguagem Natural (Tokenização, Embeddings, Transformers) ou Visão Computacional (CNNs), dependendo da especialização.
Q11	Big Data & Cloud	Processamento distribuído com PySpark. Manipulação de grandes volumes de dados em nuvem (AWS SageMaker ou Azure ML).
Q12	Deploy e MLOps	Transformação de modelos em APIs (FastAPI/Flask). Monitoramento de Drifting de dados e versionamento de modelos com MLflow.

Diferenciais do Cientista de Dados Sênior

- **Rigor Matemático:** O sênior não apenas "roda o código", ele entende a função de perda (*loss function*) que está sendo minimizada.
- **Visão de Negócio:** Capacidade de traduzir uma dor do mundo real em um problema de modelagem (ex: transformar "perda de clientes" em um modelo de *Churn*).
- **Storytelling:** A habilidade de explicar a incerteza estatística para tomadores de decisão de forma clara e visual.